

TRƯỜNG ĐẠI HỌC THỦY LỢI

PHÂN HIỆU

-----o0o-----

ĐỀ TÀI: ỨNG DỤNG KHAI PHÁ DỮ LIỆU TRONG
PHÂN LOẠI CHẤT LƯỢNG RAU XÀ LÁCH

ĐỒ ÁN MÔN: KHAI PHÁ DỮ LIỆU

Mã sinh viên	Tên sinh viên
2251068268	Phạm Tuyết Trinh
2251068242	Lê Huy Sáng
2251068246	Trần Phước Tài

Hồ Chí Minh – 10/2025

TRƯỜNG ĐẠI HỌC THỦY LỢI

PHÂN HIỆU

-----o0o-----

ĐỀ TÀI: ỨNG DỤNG KHAI PHÁ DỮ LIỆU TRONG
PHÂN LOẠI CHẤT LƯỢNG RAU XÀ LÁCH

ĐỒ ÁN MÔN: KHAI PHÁ DỮ LIỆU

Mã sinh viên	Tên sinh viên
2251068268	Phạm Tuyết Trinh
2251068242	Lê huy Sáng
2251068246	Trần Phước Tài

Giáo viên hướng dẫn: TS. Vũ Thị Như Hạnh

Hồ Chí Minh - 10/2025

DANH MỤC CÁC KÝ HIỆU, CHỮ VIẾT TẮT

Chữ viết tắt	Nguyên nghĩa

DANH MỤC CÁC BẢNG HÌNH VẼ ĐỒ THỊ

Hình 1. 1: Trực quan cách hoạt động của lớp Convolution2D.....	18
Hình 1. 2: Trực quan lớp Dense (FullyConnect layer).....	19
Hình 1. 3: Trực quan lớp Dropout.....	20
Hình 1. 4: Python.....	22
Hình 1. 5: OpenCV + Python.....	23
Hình 1. 6: Tensorflow + Keras.....	24
Hình 1. 7: Numpy.....	25
Hình 1. 8: Pillow.....	25
Hình 2. 1: Một số ảnh của dataset.....	27
Hình 2. 2: Kiến trúc fine tuning VGG19.....	30
Hình 2. 3: Kiến trúc fine tuning InceptionV3.....	31
Hình 2. 4: kiến trúc fine tunin ResNet50.....	32

MỤC LỤC

DANH MỤC CÁC KÝ HIỆU, CHỮ VIẾT TẮT.....	3
DANH MỤC CÁC BẢNG HÌNH VẼ ĐỒ THỊ.....	4
LỜI NÓI ĐẦU.....	6
CHƯƠNG 1 - TỔNG QUAN (CƠ SỞ LÝ THUYẾT).....	7
1.1 Giới thiệu về đề tài.....	7
1.1.1 Lý do chọn đề tài.....	7
1.1.2 Mục tiêu của đề tài.....	8
1.1.3 Phương pháp thực hiện.....	9
1.1.4 Đối tượng và phạm vi nghiên cứu đề tài.....	11
1.2 Nghiên cứu tổng quan.....	12
1.2.1 Tổng quan về khai phá dữ liệu.....	12
1.2.2 Tổng quan về ứng dụng khai phá dữ liệu trong nông nghiệp.....	13
1.2.3 Tổng quan về bài toán phân loại rau xà lách.....	14
1.3 Cơ sở lý thuyết và công nghệ được sử dụng.....	14
1.3.1 Thị giác máy tính là gì?.....	14
1.3.2 Thị giác máy tính hoạt động như thế nào?.....	15
1.3.3 Lịch sử thị giác máy tính.....	16
1.3.4 Lớp Convolution 2d (Conv2D).....	17
1.3.5 Lớp Dense(Fully Connected Layer).....	18
1.3.6 Lớp Dropout.....	19
1.3.6 Các hàm kích hoạt phổ biến (Activation function).....	20
1.3.7 Các chỉ số đánh giá mô hình.....	20
1.3.8 Kỹ thuật chuyển giao học tập (Transfer Learning).....	21
1.4 Các công cụ hỗ trợ.....	22
CHƯƠNG 2: XÂY DỰNG MÔ HÌNH PHÂN LOẠI RAU XÀ LÁCH (LETTUCE).....	25
2.1 Giới thiệu tập dữ liệu.....	25
2.2 Tiền xử lý dữ liệu.....	27
2.3 Chia dữ liệu thành train, test và validation.....	28
2.5 Mô hình và phương pháp sử dụng.....	29
CHƯƠNG 3: THỰC NGHIỆM VÀ KẾT QUẢ ĐẠT ĐƯỢC.....	33

3.1. Thực nghiệm.....	33
3.1.1. Môi trường và cấu hình thực nghiệm.....	33
3.2. Kết quả thực nghiệm.....	35
3.2.1. Kết quả huấn luyện.....	35
3.2.3. Trực quan hóa bản đồ đặc trưng (Feature Map Visualization).....	36
3.3. Nhận xét kết quả.....	37
NHẬN XÉT VÀ KẾT LUẬN.....	40
HƯỚNG PHÁT TRIỂN.....	42
TÀI LIỆU THAM KHẢO.....	42

LỜI NÓI ĐẦU

Trong thời đại công nghệ 4.0, dữ liệu đã trở thành một trong những tài nguyên quan trọng nhất, đóng vai trò then chốt trong việc ra quyết định và tối ưu hóa quy trình trong nhiều lĩnh vực. Khai phá dữ liệu (Data Mining) là một lĩnh vực của khoa học dữ liệu, tập trung vào việc khám phá các mẫu, mối quan hệ và tri thức tiềm ẩn trong khối lượng dữ liệu lớn. Việc ứng dụng các kỹ thuật khai phá dữ liệu không chỉ giúp nâng cao hiệu quả xử lý thông tin mà còn góp phần tự động hóa các quá trình phân tích, dự đoán và nhận dạng.

Trong nông nghiệp hiện đại, đặc biệt là trong lĩnh vực trồng trọt và kiểm định chất lượng nông sản, việc đánh giá và phân loại sản phẩm đóng vai trò vô cùng quan trọng. Rau xà lách là một loại rau phổ biến, được tiêu thụ rộng rãi, tuy nhiên chất lượng của nó có thể bị ảnh hưởng bởi điều kiện môi trường, quá trình bảo quản và vận chuyển. Vì vậy, việc phân loại rau xà lách thành hai nhóm: “healthy” (đạt chất lượng) và “unhealthy” (không đạt chất lượng) có ý nghĩa thiết thực trong việc hỗ trợ công tác kiểm định, giảm thiểu thất thoát và nâng cao giá trị sản phẩm.

Đề tài “Ứng dụng khai phá dữ liệu trong phân loại rau xà lách (healthy và unhealthy)” được thực hiện nhằm mục tiêu tìm hiểu, áp dụng các kỹ thuật khai phá dữ liệu và học máy để xây dựng mô hình phân loại tự động dựa trên dữ liệu hình ảnh rau xà lách. Qua đó, sinh viên có cơ hội củng cố kiến thức lý thuyết, rèn luyện kỹ năng xử lý dữ liệu, trích xuất đặc trưng và đánh giá mô hình trong thực tế.

Nhóm chúng em xin chân thành cảm ơn thầy, cô giảng dạy môn Khai phá dữ liệu đã tận tình hướng dẫn và giúp đỡ chúng em trong suốt quá trình học tập và thực hiện đề tài này.

CHƯƠNG 1 - TỔNG QUAN (CƠ SỞ LÝ THUYẾT)

1.1 Giới thiệu về đề tài

1.1.1 Lý do chọn đề tài

Trong bối cảnh hiện nay, an toàn thực phẩm và chất lượng nông sản là vấn đề được xã hội đặc biệt quan tâm. Việc nhận biết và phân loại thực phẩm đạt chuẩn hay không đạt chuẩn đóng vai trò quan trọng trong quá trình sản xuất, phân phối và tiêu dùng. Tuy nhiên, việc kiểm tra chất lượng nông sản, đặc biệt là rau xanh như xà lách, thường được thực hiện thủ công bằng mắt thường, dễ bị ảnh hưởng bởi yếu tố chủ quan của con người và tốn nhiều thời gian.

Sự phát triển mạnh mẽ của các công nghệ trong lĩnh vực trí tuệ nhân tạo, học máy và khai phá dữ liệu đã mở ra hướng đi mới cho việc tự động hóa quá trình đánh giá chất lượng nông sản. Việc áp dụng các kỹ thuật này vào phân loại rau xà lách giúp tăng độ chính xác, tiết kiệm thời gian, đồng thời hỗ trợ người nông dân và doanh nghiệp trong việc kiểm soát chất lượng sản phẩm.

Từ những lý do trên, nhóm chúng em quyết định chọn đề tài “Ứng dụng khai phá dữ liệu trong phân loại rau xà lách (healthy và unhealthy)” với mong muốn vận dụng kiến thức đã học vào một bài toán thực tế, góp phần tìm hiểu và phát triển các ứng dụng khai phá dữ liệu trong lĩnh vực nông nghiệp thông minh.

1.1.2 Mục tiêu của đề tài

Đề tài “Ứng dụng khai phá dữ liệu trong phân loại rau xà lách (healthy và unhealthy)” được thực hiện với mục tiêu vận dụng các kiến thức đã học trong môn Khai phá dữ liệu vào một bài toán thực tế, qua đó giúp người học hiểu rõ hơn quy trình xử lý dữ liệu, xây dựng mô hình và đánh giá kết quả trong một ứng dụng cụ thể.

Cụ thể, đề tài hướng đến các mục tiêu sau:

- Tìm hiểu lý thuyết và các phương pháp trong khai phá dữ liệu: Nắm vững các khái niệm cơ bản về khai phá dữ liệu, các bước trong quy trình KDD (Knowledge Discovery in Databases), bao gồm thu thập dữ liệu, làm sạch dữ liệu, trích xuất đặc trưng, lựa chọn mô hình và đánh giá kết quả. Đồng thời, tìm hiểu các thuật toán phân loại phổ biến như Decision Tree, KNN, SVM, hoặc các mô hình học sâu (Deep Learning) áp dụng cho dữ liệu hình ảnh.
- Thu thập và xử lý dữ liệu hình ảnh rau xà lách: Xây dựng bộ dữ liệu gồm hình ảnh các loại rau xà lách ở hai trạng thái: healthy (rau tươi, đạt chất lượng) và unhealthy (rau hư, úa, dập nát hoặc có dấu hiệu hỏng). Thực hiện các bước tiền xử lý dữ liệu như cắt, xoay, chuẩn hóa kích thước, cân bằng dữ liệu và tách dữ liệu thành tập huấn luyện, kiểm thử và đánh giá.
- Xây dựng và huấn luyện mô hình phân loại: Ứng dụng các kỹ thuật khai phá dữ liệu và học máy để xây dựng mô hình có khả năng phân biệt hai nhóm rau xà lách. Thử nghiệm nhiều phương pháp khác nhau (Machine Learning truyền thống hoặc Deep Learning như CNN) để tìm ra mô hình có hiệu quả cao nhất.
- Đánh giá và so sánh kết quả mô hình: Sử dụng các chỉ số đánh giá như Accuracy, Precision, Recall, F1-score và ma trận nhầm lẫn (Confusion Matrix) để đánh giá hiệu năng mô hình. Từ đó, phân tích ưu nhược điểm của từng phương pháp và đề xuất hướng cải thiện.
- Ứng dụng thực tế và mở rộng: Đề tài không chỉ dừng lại ở việc phân loại hình ảnh trong phạm vi nghiên cứu, mà còn hướng đến khả năng ứng dụng thực tiễn trong việc hỗ trợ nông dân, nhà phân phối hoặc cơ sở kiểm định trong việc nhận dạng và đánh giá chất lượng rau nhanh chóng, chính xác hơn. Đây cũng là bước đầu trong việc ứng dụng khai phá dữ liệu và trí tuệ nhân tạo vào lĩnh vực nông nghiệp thông minh (Smart Agriculture).

Thông qua việc thực hiện đề tài, sinh viên có cơ hội củng cố kiến thức lý thuyết, nâng cao kỹ năng thực hành về xử lý dữ liệu, lập trình và phân tích kết quả, đồng

thời rèn luyện khả năng nghiên cứu, làm việc nhóm và tư duy logic trong giải quyết vấn đề thực tế.

1.1.3 Phương pháp thực hiện

Để đạt được các mục tiêu đã đề ra, đề tài được thực hiện dựa trên quy trình và các phương pháp khai phá dữ liệu kết hợp với học máy và xử lý ảnh. Quá trình thực hiện được chia thành nhiều giai đoạn cụ thể như sau:

1) Tìm hiểu lý thuyết và thu thập dữ liệu

- Trước tiên, nhóm tiến hành tìm hiểu cơ sở lý thuyết liên quan đến khai phá dữ liệu, bao gồm các bước chính của quy trình KDD (Knowledge Discovery in Databases), các phương pháp học máy (Machine Learning), và đặc biệt là các mô hình học sâu (Deep Learning) trong phân loại hình ảnh.
- Song song đó, nhóm tiến hành thu thập dữ liệu hình ảnh rau xà lách từ nhiều nguồn khác nhau như internet, các trang dữ liệu mở (Kaggle, Google Dataset Search), hoặc chụp ảnh thực tế. Dữ liệu được phân loại thành hai nhóm: healthy (rau tươi, không hư hại) và unhealthy (rau úa, héo, bị dập hoặc mốc).

2) Tiền xử lý và chuẩn hóa dữ liệu

Sau khi thu thập, dữ liệu được xử lý nhằm đảm bảo chất lượng và tính đồng nhất cho quá trình huấn luyện mô hình. Các bước tiền xử lý bao gồm:

- Loại bỏ những hình ảnh bị mờ, sai đối tượng hoặc trùng lặp.
- Cắt, xoay và thay đổi kích thước ảnh về cùng tỷ lệ phù hợp (ví dụ: 128x128 hoặc 224x224 pixel).
- Chuẩn hóa dữ liệu ảnh về cùng định dạng màu (RGB) và tỷ lệ giá trị điểm ảnh (0–1).
- Thực hiện kỹ thuật ***data augmentation*** (phóng to, xoay, lật ảnh, thay đổi độ sáng) để tăng kích thước và độ đa dạng của tập dữ liệu.

- Chia dữ liệu thành ba phần: tập huấn luyện (train), tập kiểm thử (test), và tập kiểm định (validation).

3) Trích xuất đặc trưng và lựa chọn mô hình

Sử dụng mạng nơ-ron tích chập (CNN - Convolutional Neural Network) để tự động học đặc trưng từ ảnh, giúp cải thiện độ chính xác và giảm công sức xử lý thủ công.

4) Huấn luyện và đánh giá mô hình

Sau khi lựa chọn mô hình phù hợp, nhóm tiến hành huấn luyện mô hình trên tập dữ liệu huấn luyện và kiểm định. Trong quá trình này, các tham số mô hình (learning rate, batch size, số epoch, v.v.) được điều chỉnh để tối ưu hiệu suất. Hiệu quả mô hình được đánh giá dựa trên các chỉ số:

- Accuracy (độ chính xác)
- Precision (độ chính xác theo lớp)
- Recall (độ bao phủ)
- F1-score (chỉ số cân bằng giữa precision và recall)
- Ma trận nhầm lẫn (Confusion Matrix)

5) Phân tích kết quả và rút ra kết luận

Sau khi huấn luyện, nhóm tiến hành so sánh kết quả giữa các mô hình, xác định mô hình có độ chính xác cao nhất và phân tích nguyên nhân của sự chênh lệch. Cuối cùng, rút ra nhận xét, đánh giá về khả năng ứng dụng thực tế của mô hình phân loại rau xà lách và đề xuất hướng phát triển trong tương lai như mở rộng dữ liệu, áp dụng thêm mô hình tiên tiến (ResNet, Inception, v.v.), hoặc triển khai hệ thống phân loại tự động bằng giao diện trực quan.

1.1.4 Đối tượng và phạm vi nghiên cứu đề tài

1) Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là dữ liệu hình ảnh rau xà lách (lettuce) ở hai trạng thái khác nhau:

- Healthy (đạt chất lượng): bao gồm những lá rau có màu xanh tươi, không bị úa, dập nát hoặc thối hỏng.
- Unhealthy (không đạt chất lượng): bao gồm những lá rau bị hư hỏng, úa vàng, mốc hoặc có dấu hiệu sâu bệnh.

Bên cạnh đó, đề tài cũng tập trung nghiên cứu các phương pháp và thuật toán khai phá dữ liệu, đặc biệt là các kỹ thuật phân loại (classification) dựa trên dữ liệu hình ảnh, nhằm xây dựng một mô hình có khả năng nhận diện và phân loại chính xác chất lượng rau.

2) Phạm vi nghiên cứu

Phạm vi nghiên cứu của đề tài tập trung vào việc phân loại hình ảnh rau xà lách, không mở rộng sang các loại rau khác. Do giới hạn về thời gian và nguồn dữ liệu, phạm vi nghiên cứu được xác định như sau:

- Dữ liệu được thu thập từ các nguồn hình ảnh công khai như Kaggle, Google Dataset Search, RoboFlow. Bộ dữ liệu được giới hạn ở quy mô nhỏ đến trung bình, đủ để huấn luyện và kiểm thử mô hình phân loại.
- Đề tài tập trung áp dụng các phương pháp khai phá dữ liệu và học máy (Machine Learning hoặc Deep Learning cơ bản) để thực hiện bài toán phân loại. Các bước xử lý bao gồm tiền xử lý dữ liệu ảnh, trích xuất đặc trưng, huấn luyện mô hình, đánh giá và so sánh kết quả.
- Đề tài mang tính thử nghiệm học thuật, nhằm minh chứng khả năng ứng dụng của khai phá dữ liệu trong việc hỗ trợ kiểm định chất lượng nông sản. Việc triển khai hệ thống nhận diện tự động hoặc ứng dụng thực tế trên thiết bị di động không thuộc phạm vi của đề tài này.

Thông qua đối tượng và phạm vi nghiên cứu trên, đề tài hướng đến việc chứng minh rằng các kỹ thuật khai phá dữ liệu và học máy có thể được áp dụng hiệu quả trong lĩnh vực nông nghiệp, đặc biệt là trong quá trình tự động hóa việc phân loại và đánh giá chất lượng rau xanh.

1.2 Nghiên cứu tổng quan

1.2.1 Tổng quan về khai phá dữ liệu

Khai phá dữ liệu (Data Mining) là quá trình phát hiện các mẫu, mối quan hệ và tri thức tiềm ẩn từ những tập dữ liệu lớn. Đây là bước quan trọng trong quy trình khám phá tri thức từ cơ sở dữ liệu (Knowledge Discovery in Databases – KDD).

Khai phá dữ liệu bao gồm nhiều kỹ thuật khác nhau như phân loại (classification), phân cụm (clustering), hồi quy (regression), khai phá luật kết hợp (association rule mining) và phát hiện ngoại lệ (outlier detection). Trong đó, phân loại dữ liệu là một trong những kỹ thuật phổ biến nhất, được ứng dụng rộng rãi trong các lĩnh vực như y tế, tài chính, giáo dục và đặc biệt là trong xử lý, nhận dạng hình ảnh.

Các thuật toán thường được sử dụng trong bài toán phân loại gồm có:

- K-Nearest Neighbors (KNN)
- Decision Tree (Cây quyết định)
- Random Forest
- Support Vector Machine (SVM)
- Neural Networks (Mạng nơ-ron nhân tạo)
- Deep Learning (đặc biệt là Convolutional Neural Networks – CNN)

Trong các bài toán phân loại hình ảnh, các mô hình học sâu như CNN tỏ ra vượt trội nhờ khả năng tự động trích xuất đặc trưng mà không cần can thiệp thủ công.

1.2.2 Tổng quan về ứng dụng khai phá dữ liệu trong nông nghiệp

Trong những năm gần đây, việc ứng dụng trí tuệ nhân tạo và khai phá dữ liệu trong lĩnh vực nông nghiệp ngày càng được quan tâm và phát triển mạnh. Các nghiên cứu tập trung vào nhiều hướng như:

- Dự đoán năng suất cây trồng dựa trên dữ liệu thời tiết và đất đai.
- Phát hiện sâu bệnh trên lá cây qua hình ảnh.
- Phân loại và đánh giá chất lượng nông sản sau thu hoạch.
- Tự động hóa quy trình trồng trọt và giám sát cây trồng thông qua cảm biến và camera.

Đối với lĩnh vực phân loại chất lượng rau quả, nhiều công trình đã sử dụng các kỹ thuật học máy và học sâu để nhận diện tình trạng của nông sản. Ví dụ:

- Nghiên cứu phân loại quả táo hoặc chuối dựa trên màu sắc và kết cấu bề mặt.
- Sử dụng CNN để nhận dạng lá cây bị bệnh.
- Ứng dụng mạng nơ-ron trong phát hiện rau hư hỏng hoặc không đạt chất lượng.

Những kết quả này cho thấy việc áp dụng khai phá dữ liệu và học sâu có tiềm năng rất lớn trong việc tự động hóa quá trình đánh giá và kiểm định chất lượng nông sản, giúp giảm thiểu sức lao động, nâng cao năng suất và độ chính xác.

1.2.3 Tổng quan về bài toán phân loại rau xà lách

Rau xà lách là loại rau lá phổ biến, thường được sử dụng trong nhiều món ăn. Tuy nhiên, chất lượng của rau dễ bị ảnh hưởng bởi điều kiện thời tiết, bảo quản và vận chuyển. Việc nhận diện rau bị hư, úa hoặc mốc bằng mắt thường dễ sai lệch, tốn thời gian và không phù hợp cho quy mô sản xuất lớn.

Vì vậy, việc xây dựng mô hình tự động phân loại rau xà lách healthy và unhealthy dựa trên hình ảnh là cần thiết. Nhiều mô hình CNN hiện đại như VGG16,

ResNet, MobileNet đã được áp dụng cho các bài toán tương tự và cho kết quả chính xác cao. Tuy nhiên, ở Việt Nam, việc áp dụng công nghệ này trong phân loại rau xanh vẫn còn hạn chế.

Đề tài “Ứng dụng khai phá dữ liệu trong phân loại rau xà lách (healthy và unhealthy)” kế thừa các hướng nghiên cứu trước, đồng thời thử nghiệm và đánh giá hiệu quả của một số mô hình phân loại khác nhau nhằm tìm ra hướng giải pháp phù hợp với điều kiện và nguồn lực thực tế.

1.3 Cơ sở lý thuyết và công nghệ được sử dụng

1.3.1 Thị giác máy tính là gì?

Thị giác máy tính là một lĩnh vực trí tuệ nhân tạo (AI) sử dụng máy học và mạng lưới thần kinh để dạy máy tính và hệ thống lấy thông tin có ý nghĩa từ hình ảnh, video kỹ thuật số và các đầu vào trực quan khác-đồng thời đưa ra đề xuất hoặc thực hiện hành động khi chúng thấy khiếm khuyết hoặc sự cố.

Nếu AI cho phép máy tính suy nghĩ thì thị giác máy tính cho phép chúng nhìn, quan sát và hiểu.

Thị giác máy tính hoạt động giống như thị giác của con người, ngoại trừ việc con người có khởi đầu thuận lợi hơn. Thị giác của con người có lợi thế là có bối cảnh trong suốt cuộc đời để rèn luyện cách phân biệt các vật thể, khoảng cách của chúng, liệu chúng có đang chuyển động hay có điều gì đó không ổn với hình ảnh.

Thị giác máy tính huấn luyện máy móc thực hiện các chức năng này, nhưng nó phải thực hiện việc đó trong thời gian ngắn hơn nhiều nhờ máy ảnh, dữ liệu và thuật toán thay vì võng mạc, dây thần kinh thị giác và vỏ não thị giác. Bởi vì một hệ thống được đào tạo để kiểm tra sản phẩm hoặc theo dõi tài sản sản xuất có thể phân tích hàng nghìn sản phẩm hoặc quy trình trong một phút, nhận thấy những khiếm

khuyết hoặc vấn đề không thể nhận ra, nên nó có thể nhanh chóng vượt qua khả năng của con người.

1.3.2 Thị giác máy tính hoạt động như thế nào?

Thị giác máy tính cần rất nhiều dữ liệu. Nó chạy đi phân tích dữ liệu nhiều lần cho đến khi phân biệt được sự khác biệt và cuối cùng nhận ra được hình ảnh. Ví dụ, để huấn luyện máy tính nhận dạng lớp ô tô, nó cần được cung cấp một lượng lớn hình ảnh lớp và các mục liên quan đến lớp để tìm hiểu sự khác biệt và nhận biết lớp, đặc biệt là lớp không có khuyết tật.

Hai công nghệ thiết yếu được sử dụng để thực hiện điều này: một loại máy học được gọi là học sâu và mạng nơ-ron tích chập (CNN).

Học máy sử dụng các mô hình thuật toán cho phép máy tính tự dạy về bối cảnh của dữ liệu trực quan. Nếu đủ dữ liệu được cung cấp qua mô hình, máy tính sẽ “nhìn” vào dữ liệu và tự dạy mình cách phân biệt hình ảnh này với hình ảnh khác. Các thuật toán cho phép máy tự học thay vì ai đó lập trình để nhận dạng hình ảnh.

CNN giúp mô hình học máy hoặc học sâu “nhìn” bằng cách chia hình ảnh thành các pixel được gắn thẻ hoặc nhãn. Nó sử dụng các nhãn để thực hiện các phép tích chập (một phép toán trên hai hàm để tạo ra hàm thứ ba) và đưa ra dự đoán về những gì nó “nhìn thấy”. Mạng lưới thần kinh chạy các phép tích chập và kiểm tra tính chính xác của các dự đoán của nó trong một loạt các lần lặp cho đến khi các dự đoán bắt đầu trở thành hiện thực. Sau đó nó nhận biết hoặc nhìn thấy hình ảnh theo cách tương tự như con người.

1.3.3 Lịch sử thị giác máy tính

Thị giác máy tính ra đời cùng với sự phát triển của trí tuệ nhân tạo và khoa học máy tính. Trong thập niên 1950, các nhà khoa học bắt đầu thử nghiệm cho máy tính “nhìn thấy” thế giới thực thông qua hình ảnh. Những nghiên cứu đầu tiên tập

trung vào việc chuyển đổi hình ảnh sang dạng số (digital image) và phát hiện cạnh (edge detection). Một trong những dự án nổi bật là của Larry Roberts (MIT, 1963), được xem là “cha đẻ của thị giác máy tính”, với công trình mô hình hóa thế giới 3D từ hình ảnh 2D.

Trong giai đoạn này, thị giác máy tính phát triển mạnh mẽ nhờ các kỹ thuật xử lý ảnh số (digital image processing). Các phương pháp như phân ngưỡng (thresholding), phát hiện biên (Canny, Sobel), và biến đổi Hough ra đời, giúp máy tính có thể nhận diện các hình dạng cơ bản như đường thẳng, hình tròn. Song song đó, các nghiên cứu về nhận dạng ký tự quang học (OCR), phân tích chuyển động và nhận dạng khuôn mặt ở mức đơn giản bắt đầu được triển khai. Thị giác máy tính vẫn chủ yếu dựa trên các thuật toán quy tắc thủ công (rule-based).

Thập niên 1990 đánh dấu sự xuất hiện của machine learning trong thị giác máy tính. Các mô hình như SVM (Support Vector Machine), k-NN, và HOG (Histogram of Oriented Gradients) được dùng rộng rãi cho bài toán nhận dạng khuôn mặt, vật thể, và cảnh vật. Những năm 2000, các hệ thống như Viola–Jones (2001) giúp nhận dạng khuôn mặt thời gian thực trở nên khả thi — là bước ngoặt lớn cho ứng dụng thị giác trong camera, robot, và an ninh.


Từ năm 2012, sau chiến thắng của mô hình AlexNet tại cuộc thi ImageNet, mạng nơ-ron tích chập (CNN) đã thay đổi toàn bộ cục diện thị giác máy tính. Các mô hình nổi tiếng như VGGNet, ResNet, Inception, EfficientNet đã đưa độ chính xác nhận dạng hình ảnh lên mức vượt trội so với các phương pháp truyền thống. Nhờ deep learning, máy tính có thể nhận dạng khuôn mặt, phát hiện vật thể, phân tích hành vi, tái tạo ảnh, và thậm chí “hiểu” nội dung video. Công nghệ này hiện diện trong xe tự lái, camera thông minh, y học chẩn đoán hình ảnh, và nhiều lĩnh vực khác.

Ngày nay, thị giác máy tính đang bước vào kỷ nguyên AI đa phương thức (multimodal AI) — nơi hình ảnh, âm thanh, và ngôn ngữ được xử lý cùng nhau. Các mô hình như CLIP, DALL·E, Segment Anything (SAM), và GPT-4V/5V cho phép AI hiểu và tạo ra hình ảnh dựa trên mô tả văn bản. Trong tương lai, thị giác máy tính không chỉ dừng ở việc “nhìn thấy” mà còn có thể “hiểu”, “suy luận” và “tương tác” với thế giới vật lý một cách thông minh, mở ra kỷ nguyên của robot tự chủ và thực tế ảo tăng cường (AR/VR).

1.3.4 Lớp Convolution 2d (Conv2D)

- Chức năng: Lớp Convolution (tích chập 2 chiều) là lớp nền tảng của mạng CNN, có nhiệm vụ trích xuất đặc trưng cục bộ từ ảnh đầu vào (ví dụ: cạnh, góc, đường nét của khuôn mặt, mắt, mũi, miệng...).
- Nguyên lý: Lớp Conv2D sử dụng các bộ lọc (kernel/filter) có kích thước nhỏ (thường 3×3 hoặc 5×5) quét qua toàn bộ ảnh đầu vào và tính tích chập giữa kernel với từng vùng nhỏ của ảnh.
- Công thức:

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n)$$



Hình 1. 1: Trực quan cách hoạt động của lớp Convolution2D

1.3.5 Lớp Dense(Fully Connected Layer)


- Đây là lớp thường xuất hiện ở cuối mạng CNN, nơi các đặc trưng đã được trích xuất bởi các lớp tích chập (Conv2D) và gộp (Pooling) được tổng hợp để đưa ra kết quả cuối cùng.
- Công thức:

$$z_j = \sum_{i=1}^n w_{ij}x_i + b_j$$

$$a_j = f(z_j)$$

Trong đó:


- x_i : đầu vào thứ i từ lớp trước
- w_{ij} : Trọng số
- b_j : hệ số điều chỉnh (bias).
- $f(z_j)$: hàm kích hoạt



Hình 1. 2: Trực quan lớp Dense (FullyConnect layer)

1.3.6 Lớp Dropout

- Lớp Dropout là một kỹ thuật regularization giúp giảm hiện tượng overfitting (quá khớp) khi huấn luyện mạng neuron.
- Trong quá trình học, một tỷ lệ phần trăm ngẫu nhiên của các neuron trong lớp sẽ bị tạm thời vô hiệu hóa (set = 0) ở mỗi bước huấn luyện.



Hình 1. 3: Trực quan lớp Dropout

1.3.6 Các hàm kích hoạt phổ biến (Activation function)

1. Hàm Sigmoid

$$f(x) = \frac{1}{1 + e^{-x}}$$

2. Hàm ReLu

$$f(x) = \max(0, x)$$

1.3.7 Các chỉ số đánh giá mô hình.

1) Độ chính xác (Accuracy)

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

→ Tỷ lệ đoán đúng trên tổng số mẫu.

2) Độ chính xác dương (Precision):

$$Precision = \frac{TP}{TP + FP}$$

→ Trong các mẫu được dự đoán là “bệnh”, có bao nhiêu mẫu thật sự bệnh.

3) Độ bao phủ (Recall):

$$Recall = \frac{TP}{TP + FN}$$

→ Trong các mẫu thực sự bệnh, mô hình được phát hiện bao nhiêu

4) F1-score:

$$Recall = \frac{TP}{TP + FN}$$

→ Trung bình điều hòa giữa Precision và Recall.

1.3.8 Kỹ thuật chuyển giao học tập (Transfer Learning)

Transfer Learning (Học chuyển giao) là một kỹ thuật trong học sâu (Deep Learning) cho phép sử dụng lại một mô hình đã được huấn luyện trước đó trên một tập dữ liệu lớn (chẳng hạn như ImageNet) để áp dụng cho một bài toán mới có dữ liệu nhỏ hơn.

Thay vì huấn luyện mô hình từ đầu, Transfer Learning giúp tận dụng tri thức đã học từ bài toán gốc (ví dụ: khả năng nhận diện đặc trưng hình dạng, màu sắc, kết cấu trong hình ảnh) và điều chỉnh để phù hợp với bài toán mục tiêu.

Lợi ích của Transfer Learning:

- Giảm đáng kể thời gian huấn luyện mô hình.
- Hạn chế hiện tượng overfitting khi dữ liệu huấn luyện hạn chế.
- Tận dụng tri thức từ các mô hình lớn, giúp cải thiện độ chính xác trên bài toán mới.

Quy trình áp dụng Transfer Learning trong đề tài:

1. Nạp mô hình gốc: Sử dụng các mô hình nổi tiếng đã được huấn luyện sẵn trên bộ dữ liệu ImageNet như VGG19, ResNet50 hoặc InceptionV3.
2. Đóng băng (freeze) các lớp tích chập ban đầu: Giữ nguyên trọng số của các lớp này để bảo toàn tri thức đã học được từ dữ liệu gốc.
3. Thêm các lớp phân loại mới: Bổ sung các lớp Dense, Dropout và Softmax phù hợp với số lượng nhãn của bài toán phân loại rau xà lách (healthy và unhealthy).

4. Huấn luyện lại mô hình: Tiến hành huấn luyện các lớp mới (và có thể tinh chỉnh một phần các lớp cuối) trên bộ dữ liệu hình ảnh rau xà lách để mô hình thích ứng với đặc trưng của bài toán mới.

Nhờ phương pháp này, đề tài có thể đạt được kết quả phân loại tốt hơn trong khi vẫn tiết kiệm thời gian và tài nguyên so với việc huấn luyện toàn bộ mô hình từ đầu.

1.4 Các công cụ hỗ trợ

1. Python



Hình 1. 4: Python

Python là ngôn ngữ lập trình máy tính bậc cao thường được sử dụng để xây dựng trang web và phần mềm, tự động hóa các tác vụ và tiến hành phân tích dữ liệu. Python là ngôn ngữ có mục đích chung, nghĩa là nó có thể được sử dụng để tạo nhiều chương trình khác nhau và không chuyên biệt cho bất kỳ vấn đề cụ thể nào.


2. OpenCV



Hình 1. 5: OpenCV + Python

OpenCV là một thư viện mã nguồn mở phổ biến được sử dụng rộng rãi cho xử lý hình ảnh và video trong Python. Nó được thiết kế để cung cấp một loạt các công cụ và chức năng để xử lý và phân tích hình ảnh, từ các thao tác đơn giản như đọc và ghi hình ảnh đến các nhiệm vụ phức tạp như nhận diện khuôn mặt, theo dõi vật thể, và thậm chí là xây dựng ứng dụng thị giác máy tính

3. TensorFlow và Keras:



Hình 1. 6: Tensorflow + Keras

Keras chạy trên các thư viện máy mã nguồn mở như TensorFlow, Theano hoặc Bộ công cụ nhận thức (CNTK). Theano là một thư viện python được sử dụng cho các tác vụ tính toán số nhanh. TensorFlow là thư viện toán học biểu tượng nổi tiếng nhất được sử dụng để tạo mạng nơ-ron và mô hình

học sâu. TensorFlow rất linh hoạt và lợi ích chính là tính toán phân tán. CNTK là khung học sâu được phát triển bởi Microsoft. Nó sử dụng các thư viện như Python, C #, C ++ hoặc các bộ công cụ học máy độc lập. Theano và TensorFlow là những thư viện rất mạnh nhưng khó hiểu để tạo mạng nơ-ron.

Keras chạy trên các thư viện máy mã nguồn mở như TensorFlow, Theano hoặc Bộ công cụ nhận thức (CNTK). Theano là một thư viện python được sử dụng cho các tác vụ tính toán số nhanh. TensorFlow là thư viện toán học biểu tượng nổi tiếng nhất được sử dụng để tạo mạng nơ-ron và mô hình học sâu. TensorFlow rất linh hoạt và lợi ích chính là tính toán phân tán. CNTK là khung học sâu được phát triển bởi Microsoft. Nó sử dụng các thư viện như Python, C #, C ++ hoặc các bộ công cụ học máy độc lập. Theano và TensorFlow là những thư viện rất mạnh nhưng khó hiểu để tạo mạng nơ-ron

4. Numpy



Hình 1. 7: Numpy

Numpy (Numeric Python): là một thư viện toán học rất phổ biến và mạnh mẽ của Python. NumPy được trang bị các hàm số đã được tối ưu, cho phép làm việc hiệu quả với ma trận và mảng, đặc biệt là dữ liệu ma trận và mảng lớn với tốc độ xử lý nhanh hơn nhiều lần khi chỉ sử dụng Python đơn thuần.

5. Pillow



Hình 1. 8: Pillow

PIL là viết tắt của Python Image Library. Đây là một trong những thư viện mạnh mẽ, hỗ trợ một loạt các định dạng hình ảnh như PPM, JPEG, TIFF, GIF, PNG và BMP.

Nó có thể giúp bạn thực hiện một số thao tác trên hình ảnh như xoay, thay đổi kích thước, cắt xén, chia tỷ lệ màu xám, v.v.

CHƯƠNG 2: XÂY DỰNG MÔ HÌNH PHÂN LOẠI RAU XÀ LÁCH (LETTUCE)

2.1 Giới thiệu tập dữ liệu

- Trong đề tài “Phân loại rau xà lách (lettuce) healthy và unhealthy”, dữ liệu hình ảnh đóng vai trò rất quan trọng, là cơ sở để mô hình học và nhận diện đặc trưng của hai loại rau: đạt chất lượng (healthy) và không đạt chất lượng (unhealthy).
- Bộ dữ liệu được thu thập từ nhiều nguồn khác nhau:
 - o Các kho dữ liệu công khai như Kaggle, Google Dataset Search, và Roboflow.

- Một phần hình ảnh được tự thu thập từ thực tế hoặc các trang web nông nghiệp, siêu thị trực tuyến để tăng tính đa dạng cho dữ liệu.
- Mỗi hình ảnh đều thể hiện rõ đặc điểm của lá xà lách, bao gồm cả màu sắc, kết cấu, độ tươi và các dấu hiệu hư hại như úa vàng, dập nát, hoặc mốc.
- Bộ dữ liệu được chia thành hai nhóm chính:
 - Healthy: Bao gồm các hình ảnh rau xà lách tươi, có màu xanh đều, không bị hư hại hoặc biến dạng.
 - Unhealthy: Bao gồm các hình ảnh rau bị úa, thối, có đốm nâu, mốc hoặc mất độ tươi.
- Tổng số lượng hình ảnh khoảng 2500 ảnh, được chia đều cho hai lớp
- Định dạng ảnh: .jpg, .png.
- Kích thước trung bình của tất cả các ảnh : 638.35 x 630.56



Hình 2. 1: Một số ảnh của dataset

2.2 Tiền xử lý dữ liệu

Trước khi đưa dữ liệu vào huấn luyện, dữ liệu được xử lý qua các bước:

- Loại bỏ ảnh bị lỗi hoặc không chứa rau xà lách.
- Cân bằng số lượng ảnh giữa hai lớp healthy và unhealthy.
- Chuẩn hóa giá trị pixel về khoảng $[0, 1]$.
- Thực hiện data augmentation như xoay, lật, thay đổi độ sáng hoặc độ bão hòa để tăng tính đa dạng của tập dữ liệu và giúp mô hình học tốt hơn.

```
1 train_datagen = ImageDataGenerator(  
2     rescale=1./255,  
3     rotation_range=10,  
4     brightness_range=[0.8, 1.3],  
5     zoom_range=0.1,  
6     width_shift_range=0.1,  
7     height_shift_range=0.1,  
8     horizontal_flip=True,  
9 )  
10  
11 val_datagen = ImageDataGenerator(rescale=1./255)
```

- `rescale=1./255`: chuẩn hóa pixel từ $[0, 255]$ về $[0, 1]$
- `rotation_range=10`: xoay ngẫu nhiên ảnh trong khoảng ± 10 độ để tăng tính bất biến của mô hình với góc chụp.
- `brightness_range=[0.8, 1.3]`: thay đổi độ sáng ngẫu nhiên (giảm tới 0.8 lần hoặc tăng tới 1.3 lần) — hữu ích khi ảnh có điều kiện ánh sáng khác nhau.
- `zoom_range=0.1`: phóng/thu ảnh ngẫu nhiên trong khoảng $\pm 10\%$.

- `width_shift_range=0.1, height_shift_range=0.1`: dịch ngang/dọc tới 10% kích thước — giúp mô hình không phụ thuộc vào vị trí đối tượng.
- `horizontal_flip=True`: lật ngang ngẫu nhiên

2.3 Chia dữ liệu thành train, test và validation

Bộ dữ liệu được phân chia thành:

- Tập huấn luyện (Training set): chiếm khoảng 80% tổng số dữ liệu.
- Tập kiểm định (Validation set): chiếm khoảng 10% dữ liệu, dùng để điều chỉnh tham số mô hình.
- Tập kiểm thử (Test set): chiếm khoảng 10% còn lại, dùng để đánh giá hiệu suất mô hình.

```

3 TEST_SIZE = 0.1
4 VALID_SIZE = 0.1
5
1 img_paths = []
2 labels = []
3
4 for class_name in os.listdir(DATA_PATH):
5     for img in os.listdir(f'{DATA_PATH}/{class_name}'):
6         img_paths.append(f'{DATA_PATH}/{class_name}/{img}')
7         labels.append(class_name)
8
9 df = pd.DataFrame({"img_path": img_paths, "label": labels})
10
1 df_train, X_test = train_test_split(df, test_size=TEST_SIZE, stratify=df['label'], random_state=42)
2 X_train, X_val = train_test_split(df_train, test_size=VALID_SIZE, stratify=df_train['label'], random_state=42)

```

2.5 Mô hình và phương pháp sử dụng

Trong đề tài, nhóm sử dụng Transfer Learning – kỹ thuật học chuyển giao nhằm tận dụng tri thức từ các mô hình đã được huấn luyện sẵn trên tập dữ liệu lớn ImageNet để áp dụng vào bài toán phân loại rau xà lách. Ba mô hình được lựa chọn gồm: VGG19, InceptionV3, và ResNet50.

1) Mô hình VGG19

VGG19 là mạng CNN sâu gồm 19 lớp, nổi bật với cấu trúc đơn giản (nhiều lớp tích chập 3x3 xếp chồng). Trong đề tài, nhóm sử dụng phiên bản VGG19 đã được huấn luyện sẵn trên ImageNet và đóng băng toàn bộ các lớp, chỉ mở huấn luyện (fine-tune) lại 10 lớp cuối để mô hình thích nghi với dữ liệu rau xà lách. Phần phân loại được thêm gồm:

- Lớp GlobalAveragePooling2D giúp giảm số lượng tham số.
- Lớp Dense(128, activation='relu') để học đặc trưng phi tuyến.
- Lớp Dropout(0.5) giúp tránh overfitting.
- Lớp Dense(1, activation='sigmoid') cho kết quả phân loại nhị phân (healthy / unhealthy).

```
1 fine_tune_vgg19.summary()
```

Model: "sequential"

Layer (type)	Output Shape	Param #
vgg19 (Functional)	(None, 7, 7, 512)	20,024,384
global_average_pooling2d (GlobalAveragePooling2D)	(None, 512)	0
dense (Dense)	(None, 128)	65,664
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 1)	129

Total params: 20,090,177 (76.64 MB)
 Trainable params: 17,764,609 (67.77 MB)
 Non-trainable params: 2,325,568 (8.87 MB)

Hình 2. 2: Kiến trúc fine tuning VGG19

2) Mô hình InceptionV3

InceptionV3 là một kiến trúc CNN hiện đại với các khối tích hợp nhiều kích thước kernel, giúp mô hình học được đặc trưng ở nhiều cấp độ.

Cấu trúc được tinh chỉnh gồm:

- Các lớp của InceptionV3 được giữ nguyên trọng số ImageNet.

- Thêm các lớp Dense ($1024 \rightarrow 128 \rightarrow 1$) xen kẽ với Dropout (0.5) để tăng khả năng khái quát.

```
1 fine_tune_inceptionv3.summary()
```

Model: "sequential_1"

Layer (type)	Output Shape	Param #
inception_v3 (Functional)	(None, 5, 5, 2048)	21,802,784
global average pooling2d_1 (GlobalAveragePooling2D)	(None, 2048)	0
dense_2 (Dense)	(None, 1024)	2,098,176
dropout_1 (Dropout)	(None, 1024)	0
dense_3 (Dense)	(None, 128)	131,200
dropout_2 (Dropout)	(None, 128)	0
dense_4 (Dense)	(None, 1)	129

Total params: 24,032,289 (91.68 MB)
 Trainable params: 23,997,857 (91.54 MB)
 Non-trainable params: 34,432 (134.50 KB)

Hình 2. 3: Kiến trúc fine tuning InceptionV3

3) Mô hình ResNet50

ResNet50 sử dụng cơ chế residual connections giúp tránh hiện tượng biến mất gradient khi mạng sâu.

Trong đề tài, nhóm chỉ mở huấn luyện 100 lớp cuối cùng, đồng thời thêm phần phân loại gồm:

- Lớp GlobalAveragePooling2D
- Lớp Dense(512, activation='relu') với regularizer L2(1e-4)
- Lớp Dropout(0.3)
- Lớp Dense(1, activation='sigmoid').

```
1 fine_tune_resnet50.summary()
```

Model: "sequential_2"

Layer (type)	Output Shape	Param #
resnet50 (Functional)	(None, 7, 7, 2048)	23,587,712
global_average_pooling2d_2 (GlobalAveragePooling2D)	(None, 2048)	0
dense_5 (Dense)	(None, 512)	1,049,088
dropout_3 (Dropout)	(None, 512)	0
dense_6 (Dense)	(None, 1)	513

Total params: 24,637,313 (93.98 MB)

Trainable params: 23,201,537 (88.51 MB)

Non-trainable params: 1,435,776 (5.48 MB)

Hình 2. 4: kiến trúc fine tunin ResNet50

Các mô hình đều được huấn luyện với hàm mất mát BinaryCrossentropy, bộ tối ưu Adam với learning rate khác nhau tùy mô hình, và đánh giá bằng độ chính xác (accuracy).

CHƯƠNG 3: THỰC NGHIỆM VÀ KẾT QUẢ ĐẠT ĐƯỢC

3.1. Thực nghiệm

3.1.1. Môi trường và cấu hình thực nghiệm

Các thí nghiệm được tiến hành trên nền tảng Google Colab, sử dụng GPU NVIDIA Tesla T4 (16GB VRAM) nhằm tăng tốc độ huấn luyện mô hình. Môi trường lập trình sử dụng Python 3.10, cùng các thư viện phổ biến trong lĩnh vực học sâu và khai phá dữ liệu như:

- TensorFlow, Keras: xây dựng và huấn luyện mạng nơ-ron tích chập (CNN)
- OpenCV, NumPy, Pillow: tiền xử lý và biến đổi ảnh
- Matplotlib, Seaborn: trực quan hóa kết quả huấn luyện và kiểm thử
- Scikit-learn: tính toán độ chính xác, ma trận nhầm lẫn, và báo cáo phân loại

Bộ dữ liệu “Lettuce Health Dataset” gồm hai lớp chính:

- Healthy: ảnh lá xà lách khỏe mạnh, không có vết bệnh hay hư hại.
- Unhealthy: ảnh lá xà lách bị bệnh, có dấu hiệu sâu, nấm hoặc úa lá.

Ảnh được thu thập từ nhiều nguồn khác nhau, bao gồm trang trại thực tế và hình ảnh trên Internet. Dữ liệu được xử lý để đảm bảo tính đồng nhất và loại bỏ các yếu tố gây nhiễu. Các bước tiền xử lý gồm:

- Cắt, chuẩn hóa kích thước ảnh về 224x224 pixel.
- Chuyển sang định dạng RGB và chuẩn hóa giá trị pixel về $[0, 1]$.
- Tăng cường dữ liệu bằng các phép biến đổi ngẫu nhiên (xoay, dịch chuyển, thay đổi độ sáng, lật ảnh...) để tăng tính đa dạng và giảm overfitting.

Tập dữ liệu được chia theo tỷ lệ:

80% cho tập huấn luyện

10% cho tập kiểm định (validation)

10% cho tập kiểm tra (testing)

3.1.2. Thiết lập mô hình huấn luyện

Để đánh giá hiệu quả của phương pháp học chuyển giao (Transfer Learning), ba mô hình học sâu được lựa chọn gồm VGG19, InceptionV3 và ResNet50.

Các mô hình này đã được huấn luyện trước trên bộ dữ liệu ImageNet và được tinh chỉnh (fine-tuning) cho phù hợp với bài toán phân loại lá xà lách.

Các bước huấn luyện gồm:

1. Nạp trọng số từ mô hình huấn luyện sẵn trên ImageNet.
2. Đóng băng các lớp trích chọn đặc trưng cơ bản để giữ lại tri thức tổng quát.
3. Thêm các lớp mới (Dense, Dropout) để phù hợp với bài toán nhị phân.
4. Huấn luyện mô hình với các siêu tham số:
 - Số epoch: 30
 - Batch size: 16
 - Learning rate: từ $1e-5$ đến $5e-6$
 - Hàm mất mát: Binary Crossentropy
 - Bộ tối ưu: Adam
5. Sử dụng kỹ thuật EarlyStopping và ReduceLROnPlateau để tránh overfitting và điều chỉnh tốc độ học.

3.2. Kết quả thực nghiệm

3.2.1. Kết quả huấn luyện

Kết quả biểu đồ huấn luyện cho thấy các mô hình đều đạt độ chính xác cao sau 30 epoch.

- Mô hình InceptionV3 hội tụ nhanh và đạt độ chính xác cao nhất, đồng thời duy trì sự ổn định giữa tập huấn luyện và tập kiểm định.
- Mô hình VGG19 có độ chính xác tốt nhưng xuất hiện hiện tượng overfitting nhẹ.
- ResNet50 có độ chính xác thấp hơn do độ sâu lớn và dữ liệu huấn luyện còn hạn chế.

Từ báo cáo phân loại, có thể thấy InceptionV3 cho kết quả tốt nhất, gần như phân biệt hoàn hảo giữa hai lớp Healthy và Unhealthy.

Mô hình VGG19 hoạt động khá ổn định, nhưng bị ảnh hưởng nhẹ khi ảnh có ánh sáng mạnh hoặc nền phức tạp.

ResNet50 mặc dù có cấu trúc sâu nhưng chưa thể hiện ưu thế trong bộ dữ liệu nhỏ.


3.2.3. Trực quan hóa bản đồ đặc trưng (Feature Map Visualization)

Để hiểu rõ cơ chế học của mô hình, nhóm tiến hành trực quan hóa bản đồ đặc trưng của mô hình InceptionV3 ở các tầng tích chập khác nhau.

Kết quả cho thấy:

- Ở các lớp đầu tiên, mô hình phát hiện được các cạnh, đường viền, và vùng sáng tối.

- Ở lớp giữa, mô hình học được cấu trúc bề mặt lá, vân lá, và các vùng tổn thương.
- Ở lớp cuối, mô hình tập trung mạnh vào các vùng đặc trưng của bệnh như đốm, cháy lá, giúp cải thiện khả năng phân loại.









3.3. Nhận xét kết quả

Kết quả thực nghiệm chứng minh rằng học sâu kết hợp với Transfer Learning mang lại hiệu quả cao trong bài toán phân loại lá xà lách.

Mô hình InceptionV3 đạt hiệu năng vượt trội cả về độ chính xác, tốc độ hội tụ và khả năng tổng quát.

Việc sử dụng các kỹ thuật tăng cường dữ liệu, điều chỉnh tốc độ học và dừng sớm giúp mô hình ổn định và tránh overfitting.

Kết quả cũng gợi ý rằng việc lựa chọn mô hình phù hợp với quy mô dữ liệu có ảnh hưởng lớn đến chất lượng nhận diện.



NHẬN XÉT VÀ KẾT LUẬN

Qua quá trình nghiên cứu và thực nghiệm, đề tài “Phân loại lá xà lách khỏe mạnh và không khỏe mạnh bằng học sâu” đã đạt được những kết quả đáng khích lệ cả về mặt lý thuyết lẫn thực tiễn. Nhóm đã tiến hành tìm hiểu, so sánh và đánh giá ba mô hình học sâu phổ biến gồm VGG19, InceptionV3 và ResNet50, từ đó xác định được mô hình tối ưu nhất cho bài toán cụ thể.

Kết quả thí nghiệm cho thấy, mô hình InceptionV3 đạt độ chính xác lên đến 99,55% trên tập kiểm tra, vượt trội so với hai mô hình còn lại. Điều này cho thấy cấu trúc mô hình Inception với các tầng tích chập song song có khả năng học và trích xuất đặc trưng hình ảnh hiệu quả, phù hợp với dữ liệu có đặc điểm hình thái phức tạp như lá rau. Mô hình VGG19 cũng cho kết quả khá cao (93,3%) nhưng xuất hiện hiện tượng overfitting nhẹ, nguyên nhân có thể do độ sâu mạng lớn và dữ liệu chưa đủ đa dạng. ResNet50 mặc dù có khả năng học sâu nhờ các kết nối tắt (skip connection), song với quy mô dữ liệu hiện có, hiệu năng chưa được phát huy tối đa.

Kỹ thuật học chuyển giao (Transfer Learning) đã thể hiện vai trò quan trọng trong việc nâng cao hiệu quả mô hình. Thay vì huấn luyện mạng từ đầu với dữ liệu nhỏ, việc tận dụng các trọng số được huấn luyện sẵn trên bộ dữ liệu lớn như ImageNet giúp mô hình học nhanh hơn, ổn định hơn và hạn chế overfitting. Đây là minh chứng cho thấy Transfer Learning là một hướng đi thực tế và hiệu quả khi tài nguyên dữ liệu trong nông nghiệp còn hạn chế.

Ngoài ra, việc áp dụng các kỹ thuật tăng cường dữ liệu (Data Augmentation) như xoay ảnh, lật ảnh, điều chỉnh độ sáng và dịch chuyển vị trí giúp cải thiện đáng kể khả năng tổng quát hóa của mô hình. Những kỹ thuật tối ưu như EarlyStopping và ReduceLROnPlateau cũng góp phần ổn định quá trình huấn luyện, tránh hiện tượng học quá mức.

Kết quả trực quan hóa bản đồ đặc trưng (Feature Map Visualization) cho thấy mô hình thực sự học được các đặc trưng quan trọng: từ các cạnh và đường viền ở tầng đầu, đến cấu trúc bề mặt và vết bệnh ở tầng giữa, và cuối cùng là vùng tổn thương cụ thể ở tầng cuối. Điều này chứng minh rằng mô hình không chỉ ghi nhớ dữ liệu, mà còn có khả năng hiểu và khái quát đặc trưng thị giác, giúp nâng cao độ tin cậy khi áp dụng thực tế.

Về mặt thực tiễn, đề tài mở ra hướng ứng dụng rộng rãi trong nông nghiệp thông minh. Hệ thống phân loại tình trạng lá có thể được tích hợp vào các ứng dụng di động, robot nông nghiệp hoặc thiết bị IoT nhằm hỗ trợ người nông dân phát hiện sớm dấu hiệu bệnh, tối ưu quy trình chăm sóc cây trồng và giảm thiểu thiệt hại năng suất. Ngoài ra, kết quả nghiên cứu cũng có thể được mở rộng cho nhiều loại cây khác nhau, tạo tiền đề cho các hệ thống giám sát cây trồng thông minh dựa trên thị giác máy tính.

Tuy đạt được những kết quả khả quan, đề tài vẫn còn một số hạn chế. Quy mô tập dữ liệu chưa thực sự lớn và chưa bao quát đủ các loại bệnh, điều kiện ánh sáng và góc chụp khác nhau. Một số ảnh bị nhiễu hoặc ánh sáng gắt khiến mô hình đôi khi dự đoán sai. Hơn nữa, mô hình hiện tại vẫn có kích thước khá lớn, khó triển khai trực tiếp trên thiết bị di động có tài nguyên hạn chế.

Từ các kết quả trên, có thể kết luận rằng việc ứng dụng học sâu và Transfer Learning trong lĩnh vực nhận dạng tình trạng cây trồng là hoàn toàn khả thi và mang lại độ chính xác cao. Mô hình InceptionV3 thể hiện hiệu năng tốt nhất trong bối cảnh hiện tại và có tiềm năng ứng dụng thực tế cao. Kết quả đề tài không chỉ góp phần khẳng định vai trò của học sâu trong khai phá dữ liệu hình ảnh nông nghiệp mà còn là nền tảng cho các nghiên cứu tiếp theo trong lĩnh vực trí tuệ nhân tạo phục vụ sản xuất nông nghiệp bền vững.

HƯỚNG PHÁT TRIỂN

- Mở rộng tập dữ liệu với nhiều loại rau khác nhau (rau muống, cải ngọt, bắp cải...)
- Xây dựng ứng dụng di động hoặc hệ thống IoT nhận diện bệnh lá theo thời gian thực
- Tối ưu mô hình để triển khai trên thiết bị nhúng bằng TensorFlow Lite hoặc ONNX
- Kết hợp các kỹ thuật Explainable AI để giải thích rõ hơn quyết định của mô hình
- Sử dụng thêm các phương pháp như Vision Transformer (ViT) hoặc EfficientNet để so sánh hiệu quả

TÀI LIỆU THAM KHẢO

1. François Chollet, “Deep Learning with Python”, Manning Publications, 2021.
2. Christian Szegedy et al., “Rethinking the Inception Architecture for Computer Vision”, CVPR, 2016.
3. Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun, “Deep Residual Learning for Image Recognition”, CVPR, 2016.
4. Karen Simonyan, Andrew Zisserman, “Very Deep Convolutional Networks for Large-Scale Image Recognition”, ICLR, 2015.
5. Ian Goodfellow, Yoshua Bengio, Aaron Courville, “Deep Learning”, MIT Press, 2016.
6. Jason Brownlee, “Deep Learning for Computer Vision”, Machine Learning Mastery, 2020.

7. TensorFlow Documentation, <https://www.tensorflow.org/>
8. Keras API Reference, <https://keras.io/>
9. OpenCV Official Documentation, <https://docs.opencv.org/>
10. Scikit-learn Documentation, <https://scikit-learn.org/>
11. Andrew Ng, “Machine Learning Yearning”, 2018.
12. Data Augmentation Techniques for Deep Learning, Towards Data Science, 2022.
13. A. Krizhevsky, I. Sutskever, G. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks”, NIPS, 2012.
14. Paper: EfficientNet – “Rethinking Model Scaling for Convolutional Neural Networks”, Tan & Le, ICML 2019.
15. Paper: Vision Transformer (ViT) – “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”, Dosovitskiy et al., ICLR 2021.